

Big Data

Objetivo General

El objetivo de este proyecto es que los estudiantes realicen procesamiento de datos masivos en la nube, aplicando conceptos de almacenamiento distribuido, procesamiento y programación en paralelo.

El proyecto debe demostrar la capacidad del grupo para gestionar grandes volúmenes de información, procesarlos eficientemente y generar indicadores de valor para la toma de decisiones

Instrucciones del Proyecto Grupal

1. Fuente de Datos

El dataset debe contener al menos 500,000 registros.

Puede ser estructurado o semi-estructurado (CSV, JSON, logs, etc.).

Se debe describir:

- Origen de los datos
- Estructura
- Variables principales

Se valorará el uso de datos con contexto real de negocio (finanzas, retail, transporte, etc.).

2. Almacenamiento en la Nube (GCP)

Implementar un bucket en Google Cloud Platform utilizando Google Cloud Storage

El dataset debe ser almacenado en el bucket.

Se debe incluir:

- Evidencia de creación del bucket
- Organización de los datos (carpetas, particiones si aplica)

- Justificación del uso de almacenamiento en la nube

3. Diseño de Arquitectura Big Data

Definir y justificar una arquitectura basada en GCP que incluya:

- Fuente de datos
- Ingesta (batch)
- Almacenamiento (Data Lake)
- Procesamiento distribuido

Debe incluir:

- Diagrama de arquitectura
- Explicación de componentes
- Justificación técnica

4. Procesamiento Distribuido

Implementar procesamiento de datos utilizando:

- Polars
- Dask
- Modin
- Apache Spark

Se debe realizar al menos 10 consultas por cada paquete, se espera:

- Limpieza de datos
- Transformaciones
- Eliminación o tratamiento de duplicados.
- Transformación de variables.
- Filtrado.
- Agregaciones.
- Agrupaciones.
- Ordenamiento.
- Cálculo de métricas

5. Hadoop MapReduce en Google Cloud Dataproc

Como parte del proyecto, el grupo deberá utilizar Hadoop MapReduce mediante un clúster de Google Cloud Dataproc.

Cada grupo deberá seleccionar y ejecutar al menos 3 programas MapReduce incluidos en el archivo `hadoop-mapreduce-examples.jar`. Puede utilizarse todos los programas menos **wordcount** y **grep**

No será necesario desarrollar programas MapReduce propios en Java. El objetivo de esta actividad es utilizar los programas incluidos en `hadoop-mapreduce-examples.jar` para comprender y demostrar el funcionamiento práctico de Hadoop MapReduce en un entorno distribuido.

Para cada uno de los tres programas seleccionados, el grupo deberá:

- Explicar brevemente el objetivo del programa.
- Identificar el archivo o conjunto de datos utilizado como entrada.
- Ejecutar el programa en Google Cloud Dataproc.
- Utilizar HDFS como sistema de archivos distribuido durante el procesamiento.
- Almacenar el resultado generado en HDFS.
- Explorar los resultados

Entregables

1. Informe técnico (en formato PDF) que incluya:

- Portada
- Introducción
- Dataset
- Implementación en GCP
- Procesamiento distribuido
- Operaciones (CRUD, validación, agrupaciones, agregaciones, otros)
- Hadoop: archivo utilizado, programa seleccionado, comando ejecutado

2. Código fuente

- Scripts en Python
- Uso de Polars, Dask, Modin y Spark
- Estructura ordenada

3. Fecha de entrega

Miercoles 23 de setiembre del 2026